




Program Studi
STATISTIKA
UNIVERSITAS ISLAM BANDUNG




PEMBERSIHAN DAN EKSPLORASI DATA TRANSAKSI E-COMMERCE DQLAB STORE TAHUN 2009-2012

Mata Kuliah Praktikum Data Wrangling



ANGGOTA

- **Panji Satriyatama (10060123009)**
 - **Fikran Thariq Agil (10060123022)**
 - **Jahwa Naila Putri (10060123026)**
 - **Rifelina Ayu Senja Pratama (10060123028)**
- 
- 

BAB 1

PENDAHULUAN

PEMBERSIHAN DAN EKSPLORASI DATA TRANSAKSI E-COMMERCE
DQLAB STORE TAHUN 2009–2012




LATAR BELAKANG



Pemanfaatan data transaksi penjualan menjadi aspek penting dalam menganalisis performa bisnis, efektivitas promosi, serta perilaku pelanggan. Dataset transaksi DQLab Store periode 2009–2012 merupakan data mentah yang mencakup informasi pesanan, pelanggan, nilai penjualan, diskon, serta kategori produk yang disediakan sebagai studi kasus pembelajaran berbasis data nyata (Akhlq & Bagus, 2012). Selain itu, dataset ini juga mencatat status pesanan, yaitu pesanan selesai dan pesanan dikembalikan, yang dapat digunakan untuk mengevaluasi tingkat pengembalian produk dan potensi kerugian (DQLab, 2025). Oleh karena itu, proses pembersihan dan eksplorasi data diperlukan agar data siap dianalisis dan mampu menghasilkan insight yang mendukung perbaikan strategi penjualan dan promosi di masa mendatang.

DEFINISI VARIABEL



Variabel	Tipe Data	Satuan	Satuan/Deskripsi Variabel
order_id	Integer	-	ID unik untuk setiap pesanan (order identifier) dalam dataset DQLab Store.
order_status	String	-	Status pesanan, hanya berisi dua kondisi: "Order Finished" (pesanan selesai) dan "Order Returned" (pesanan dikembalikan).
customer	String	-	Nama pelanggan yang melakukan transaksi, digunakan untuk identifikasi dan analisis perilaku pelanggan
order_date	date	Tanggal (YYYY-MM-DD)	Format kalender (misalnya YYYY-MM-DD) yang menunjukkan kapan order dilakukan, penting untuk analisis tren penjualan per bulan/tahun
order_quantity	Integer	Unit/Barang	Jumlah unit produk yang dipesan dalam satu baris transaksi (unit barang).


Variabel	Tipe Data	Satuan	Satuan/Deskripsi Variabel
sales	Decimal	Rupiah (IDR)	Nilai penjualan dalam satuan mata uang , merepresentasikan omset kotor per baris transaksi sebelum dikurangi diskon.
discount	Decimal	Persen (%)	Persentase diskon yang diberikan terhadap nilai penjualan
discount_value	Decimal	Rupiah (IDR)	Nilai nominal diskon dalam mata uang yang sama dengan sales digunakan untuk menghitung total biaya promosi dan burn rate
product_category	String	-	Kategori utama produk, yang memudahkan analisis penjualan per kelompok produk besar
product_sub_category	String	-	Subkategori produk, yang memberikan detail lebih rinci untuk analisis penjualan per jenis produk.

BAB 2

LANGKAH Pengerjaan

PEMBERSIHAN DAN EKSPLORASI DATA TRANSAKSI E-COMMERCE
DQLAB STORE TAHUN 2009–2012

LANGKAH Pengerjaan



1

Import Data ke RStudio

2.


Pembersihan Data


3

Transformasi Data

4

Eksplorasi Data





IMPORT DATA KE RSTUDIO




Pada penelitian ini, data berupa file CSV transaksi penjualan diimpor ke R menggunakan fungsi `read.csv()`

```
# 2. Import Data ke RStudio
# Membaca file CSV secara langsung untuk melihat struktur awal
sales <- read.csv("D:/Mata Kuliah Statistika Unisba/Semester 5/
Praktikum Data Wrangling/raw_data.csv")
```

Kemudian dicek menggunakan fungsi `head()`, `str()`, dan `summary()` untuk melihat tampilan data, struktur, serta ringkasan statistiknya.

Hasil pemeriksaan menunjukkan bahwa seluruh data masih terbaca sebagai tipe character dan beberapa informasi transaksi masih tergabung dalam satu kolom.

```
head(sales) # Lihat beberapa baris awal
##
order_id...order_status.....customer.....order_dat
e...order_quantity...sales.....discount...discount_value...pr
oduct_category...product_sub_category.....
## 1 +-----+-----+-----+-----+-----+-----+
-----+-----+-----+-----+-----+-----+
---+-----+-----+-----+-----+-----+
## 2 |          3 | Order Finished | Muhammed MacIntyre |
2010-10-13 |          6 | 523080 | 0.04 |
str(sales) # Cek tipe data tiap kolom
## 'data.frame': 5501 obs. of 1 variable:
## $
order_id...order_status.....customer.....order_dat
e...order_quantity...sales.....discount...discount_value...pr
oduct_category...product_sub_category.....: chr "+-----
-----+-----+-----+-----+-----+-----+
summary(sales) # Ringkasan statistik
##
order_id...order_status.....customer.....order_dat
e...order_quantity...sales.....discount...discount_value...pr
oduct_category...product_sub_category.....
##                                     Length:5501
##                                     Class      :character
## Mode :character
```

PEMBERSIHAN DATA



1. Membaca file sebagai teks panjang

Karena data mentah memiliki transaksi yang terpecah ke beberapa baris, file CSV dibaca sebagai satu teks panjang menggunakan fungsi `readLines()`. Langkah ini dilakukan untuk memudahkan penggabungan baris sehingga setiap transaksi tersusun dalam satu baris.

```
# 3. Baca file sebagai satu teks panjang untuk pembersihan
# Tujuannya untuk menggabungkan baris yang terpecah menjadi 1 b
# aris per transaksi
raw_text <- readLines(
  "D:/Mata Kuliah Statistika Unisba/Semester 5/Praktikum Data W
rangling/raw_data.csv",
  warn = FALSE
)
```

2. Menggabungkan baris yang terpecah

Setiap transaksi kemudian digabung menjadi satu baris, dengan memeriksa apakah baris baru dimulai dengan status transaksi (*Order Finished* atau *Order Returned*).


```
# 4. Gabungkan baris yang terpecah jadi satu baris per transaks
i
records <- character() # Menyimpan setiap transaksi
temp <- ""             # Menyimpan baris sementara

for (line in raw_text) {
  line <- trimws(line)  # hapus spasi di awal/akhir
  if (line == "") next  # Lewati baris kosong

  # Jika ketemu awal record baru (Order Finished/Returned) dan
  # temp tidak kosong, simpan temp
  if (grepl("Order Finished|Order Returned", line) && temp != "") {
    records <- c(records, temp) # Simpan transaksi sebelumnya
    temp <- line                # Mulai transaksi baru
  } else {
    temp <- paste(temp, line)   # Gabungkan baris yang terpecah
  }
}

records <- c(records, temp) # Simpan transaksi terakhir
length(records)           # Jumlah transaksi yang berhasil digabung

## [1] 5497
```



PEMBERSIHAN DATA



3. Membaca transaksi ke data frame sementara

Data hasil penggabungan dibaca kembali menjadi data frame menggunakan `read.table()` dengan pemisah `|`.

```
# 5. Baca transaksi ke data frame sementara
sales <- read.table(
  text = records[-1], # Hapus baris pertama(header/filler)
  sep = "|",          # Separator antar kolom
  header = FALSE,
  stringsAsFactors = FALSE,
  fill = TRUE,
  quote = ""
)
```

4. Mengecek baris bermasalah

Dilakukan pengecekan untuk mendeteksi baris dengan `order_id` yang berada di kolom yang tidak sesuai. Hasilnya, ditemukan tiga baris bermasalah, yaitu baris ke-187, 202, dan 245, yang perlu diperbaiki


```
# 6. Cek baris yang bermasalah (order_id salah posisi)
problem_rows <- which(!is.na(as.numeric(str_trim(sales$V1))) &
                     is.na(as.numeric(str_trim(sales$V2))))

## Warning in which(!is.na(as.numeric(str_trim(sales$V1))) &
## is.na(as.numeric(str_trim(sales$V2)))): NAs introduced by coercion

## Warning in which(!is.na(as.numeric(str_trim(sales$V1))) &
## is.na(as.numeric(str_trim(sales$V2)))): NAs introduced by coercion

problem_rows

## [1] 187 202 245
```



PEMBERSIHAN DATA



5. Memperbaiki baris bermasalah


Baris yang teridentifikasi bermasalah diperbaiki dengan menggeser nilai ke kolom yang sesuai agar order_id berada pada posisi yang benar. Setelah pergeseran, kolom awal diisi dengan NA

```
# 7. Tangani baris bermasalah (geser data ke kanan agar order_id  
d berada di kolom yang benar)  
for (i in problem_rows) {  
  sales[i, "V11"] <- sales[i, "V10"]  
  sales[i, "V10"] <- sales[i, "V9"]  
  sales[i, "V9"] <- sales[i, "V8"]  
  sales[i, "V8"] <- sales[i, "V7"]  
  sales[i, "V7"] <- sales[i, "V6"]  
  sales[i, "V6"] <- sales[i, "V5"]  
  sales[i, "V5"] <- sales[i, "V4"]  
  sales[i, "V4"] <- sales[i, "V3"]  
  sales[i, "V3"] <- sales[i, "V2"]  
  sales[i, "V2"] <- sales[i, "V1"]  
  sales[i, "V1"] <- NA  
}
```

6. Menghapus kolom filler dan memberi nama kolom

Kolom yang tidak diperlukan dihapus untuk merapikan dataset. Selanjutnya, setiap kolom diberi nama yang sesuai dengan isi datanya.

```
# 8. Hapus kolom filler (V1, V12) dan beri nama kolom  
sales <- sales %>% select(-V1, -V12)  
  
colnames(sales) <- c(  
  "order_id",  
  "order_status",  
  "customer",  
  "order_date",  
  "order_quantity",  
  "sales",  
  "discount",  
  "discount_value",  
  "product_category",  
  "product_sub_category"  
)
```



PEMBERSIHAN DATA



7. Membersihkan spasi dan mengubah tipe data

spasi berlebih pada kolom karakter dihapus dan tipe data setiap variabel disesuaikan.


```
sales_clean <- sales %>%  
  mutate(across(where(is.character), str_trim)) %>% # Hapus s  
  # Hapus spasi di semua kolom karakter  
  mutate(  
    order_id = as.integer(order_id), # ubah ke  
    integer  
    order_quantity = as.integer(order_quantity), # ubah ke  
    integer  
    sales = as.numeric(sales), # ubah ke  
    numeric  
    discount = as.numeric(discount), # ubah ke  
    numeric  
    discount_value = as.numeric(discount_value), # ubah ke  
    numeric  
    order_date = as.Date(order_date) # ubah ke  
    date  
  )
```

8. Mengecek data hilang

Setelah pembersihan data, dilakukan pengecekan nilai hilang pada setiap kolom. Hasilnya menunjukkan tidak terdapat nilai NA, sehingga dataset dinyatakan lengkap dan siap dianalisis.

```
colSums(is.na(sales_clean))  
  
##          order_id          order_status          custom  
er  
##              0              0  
0  
##          order_date          order_quantity          sal  
es  
##              0              0  
0  
##          discount          discount_value          product_catego  
ry  
##              0              0  
0  
## product_sub_category  
##              0
```


TRANSFORMASI DATA



1. Transformasi Tanggal

Kolom `order_date` dipecah menjadi tahun, bulan, dan hari untuk memudahkan analisis penjualan berdasarkan periode waktu.


```
# 1. Transformasi tanggal, pisah order_date menjadi tahun, bulan, hari
sales_transformed <- sales_clean %>%
  mutate(
    year = year(order_date), # Ambil tahun dari order_date
    month = month(order_date), # Ambil bulan dari order_date
    day = day(order_date) # Ambil tanggal dari order_date
  )
```

2. Menghitung Total Penjualan dan Burn Rate

Kolom `total_sales` dihitung sebagai penjualan setelah diskon, sedangkan `burn_rate` menunjukkan persentase diskon terhadap penjualan untuk melihat pengaruh promosi pada tiap transaksi.

```
# 2. Hitung total penjualan (total_sales) setelah diskon
sales_transformed <- sales_transformed %>%
  mutate(
    total_sales = sales - discount_value, # Total penjualan per transaksi
    burn_rate = ifelse(sales > 0, (discount_value / sales) * 100, 0) # Burn rate per transaksi (persentase diskon dari sales)
  )
```

TRANSFORMASI DATA



3. Mengelompokkan Ukuran Pesanan

Transaksi dikelompokkan menjadi kategori Small, Medium, dan Large berdasarkan order_quantity untuk memudahkan analisis per ukuran pesanan.

4. Menandai Transaksi Besar

Kolom big_sale dibuat untuk menandai transaksi dengan total penjualan di atas 1 juta, dengan kategori "Yes" dan "No".


5. Mengelompokkan Kategori Produk

Kategori produk dikelompokkan menjadi Tech, Office, dan Others untuk memudahkan analisis.

```
# 3. Buat kategori ukuran pesanan berdasarkan order_quantity
sales_transformed <- sales_transformed %>%
  mutate(
    order_size = case_when(
      order_quantity <= 10 ~ "Small",      # Pesanan kecil
      order_quantity <= 30 ~ "Medium",    # Pesanan sedang
      TRUE ~ "Large"                      # Pesanan besar
    )
  )
```

```
# 4. Buat flag/penanda untuk transaksi besar berdasarkan
total_sales
sales_transformed <- sales_transformed %>%
  mutate(
    big_sale = factor(
      ifelse(total_sales > 1000000, TRUE, FALSE), # TRUE jika
      transaksi >1 juta
      levels = c(FALSE, TRUE),                  #
      Definisikan urutan faktor
      labels = c("No", "Yes")                   # Ubah label
      menjadi "No" dan "Yes"
    )
  )
```

```
# 5. Kelompokkan kategori produk untuk analisis lebih mudah
sales_transformed <- sales_transformed %>%
  mutate(product_group = case_when(
    product_category == "Technology" ~ "Tech",
    product_category == "Office Supplies" ~ "Office",
    TRUE ~ "Others"
  ))
```



EKSPLORASI DATA



Eksplorasi data merupakan tahap awal analisis yang bertujuan untuk memahami pola penjualan, efektivitas promosi, dan pertumbuhan pelanggan. Pada tahap ini digunakan dua pendekatan utama, yaitu **tabulasi** untuk melihat distribusi data dan **agregasi** untuk merangkum data menjadi indikator utama yang siap dianalisis lebih lanjut.

- **PERTUMBUHAN PELANGGAN
(CUSTOMER GROWTH)**


Data menunjukkan pemulihan kinerja bisnis pada tahun 2012, ditandai dengan meningkatnya jumlah pelanggan unik menjadi 594 orang. Kenaikan ini sangat penting karena menandakan toko berhasil melakukan perluasan pasar dengan menarik konsumen-konsumen baru, bukan sekadar mengandalkan pembelian berulang dari pelanggan lama yang sama.

Tahun	Jumlah Customer	Pertumbuhan (YoY)
2009	585	-
2010	593	8
2011	581	-12
2012	594	13

Pertumbuhan Jumlah Pelanggan Unik (YoY)

Menunjukkan rebound positif pada tahun 2012







EKSPLORASI DATA



- **TREN PENJUALAN BULANAN PERKATEGORI**

Berdasarkan data penjualan periode 2009–2012, kategori Technology secara konsisten menjadi penyumbang pendapatan terbesar meskipun memiliki pola penjualan yang sangat fluktuatif atau naik-turun secara tajam setiap bulannya. Sebaliknya, kategori Furniture dan Office Supplies menunjukkan tren penjualan yang jauh lebih stabil dan konsisten sepanjang tahun. Hal ini menunjukkan bahwa kategori Technology secara konsisten menjadi penyumbang pendapatan terbesar bagi perusahaan.






EKSPLORASI DATA




- **BARANG APA YANG PALING LAKU?**



Year	Product_Category	Product_Sub_Category	Total_Sales	Total_Promo	Burn_Rate
2009	Technology	Office Machines	726746424	30183156	4,15
2009	Furniture	Chairs & Chairmats	720777774	35657726	4,95
2009	Office Supplies	Binders and Binder Accessories	404240098	21829342	5,4
2009	Furniture	Tables	381532688	22559704	5,91

Office Machines dan Chairs & Chairmats merupakan penyumbang utama pendapatan perusahaan. Dominasi Office Machines, yang mencapai puncak penjualan pada tahun 2012, menunjukkan tingginya permintaan produk teknologi, sementara kontribusi stabil Chairs & Chairmats mencerminkan kebutuhan berkelanjutan pada produk furnitur.


Temuan ini menegaskan bahwa kategori Technology dan Furniture menjadi pilar utama pendapatan perusahaan, dengan perhitungan yang didasarkan pada transaksi berstatus 'Order Finished' sehingga mencerminkan pendapatan riil.



EKSPLORASI DATA




- **JUMLAH PESANAN BERDASARKAN STATUS DAN UKURAN PAKET**



No	order_status	Large	Small	Medium
1	Order Cancelled	2	1	0
2	Order Finished	1987	1031	1906
3	Order Returned	245	104	223

Visualisasi ini menunjukkan bahwa sebagian besar pesanan berstatus Order Finished, terutama pada paket Large dan Medium, sedangkan paket Small jumlahnya lebih sedikit. Pesanan Order Returned jauh lebih rendah dibandingkan pesanan selesai dan tetap didominasi oleh paket berukuran besar. Sementara itu, Order Cancelled hampir tidak ditemukan pada semua ukuran paket, menandakan tingkat pembatalan yang sangat rendah.




EKSPLORASI DATA




- BURN RATE PROMOSI PER SUB-KATEGORI**

No	Product Sub-Category	Burn Rate (%)
1	Copiers and Fax	6.16
2	Binders and Binder Accessories	5.72
3	Scissors, Rulers and Trimmers	5.77
4	Appliances	5.65
5	Pens & Art Supplies	5.39
6	Computer Peripherals	5.33
7	Telephones and Communication	5.26
8	Storage & Organization	5.22
9	Rubber Bands	5.16
10	Tables	5.15
11	Office Furnishings	5.11
12	Office Machines	5.06
13	Paper	5.01
14	Chairs & Chairmats	4.88
15	Envelopes	4.67
16	Labels	4.55



Seluruh sub-kategori memiliki burn rate promosi di atas 4,5%, dengan Copiers and Fax sebagai yang tertinggi. Beberapa sub-kategori lain juga menunjukkan proporsi diskon yang besar, sementara Labels dan Envelopes memiliki burn rate paling rendah meskipun tetap melewati ambang batas. Hasil ini menunjukkan perlunya evaluasi strategi promosi agar diskon lebih efisien.

DAFTAR PUSTAKA




Akhlaq, & Bagus. (2012). Project Data Analysis for Retail: Sales Performance Report. Bagus Akhlaq Portfolio.

DQLab. (2025). Platform Belajar Data Science Pertama dengan Fitur AI. DQLab.Id.

Yanti, H. A., & Kotabumi, U. M. (2021). PENGOLAHAN DATA SEDERHANA MENGGUNAKAN R STUDIO. <https://jurnal.umko.ac.id/index.php/sienna/article/view/386/289>.



SEKIAN
TERIMA KASIH



**PERGI KE LAB BAWA DATA MENTAH,
DATANYA ACAK BIKIN HATI GELISAH.
UNTUNG ADA KANG ANJAR SABAR DAN RAMAH,
PRAKTIKUM DATA WRANGLING JADI LANCAR DAN BERKAH**